

量化重心从能压多低转向怎么稳、怎么可控、压在什么格式上

1) QAT 占比上升,且开始研究理论与优化器稳定性

- Scaling Law for Quantization-Aware Training: 系统研究 QAT 的 scaling 行为,尤其 W4A4。

- AGoQ: Activation and Gradient Quantization for Memory-Efficient Distributed Training of LLMs: 把量化延伸到到激活+梯度/训练侧。

低比特训练里"优化器不稳/振荡"正在成为议题,和我之前遇到的 Adam 在 4-bit 权重上不收敛一样。

2) 极低比特继续下探:sub-1bit / 1bit / 1.58bit

- TWLA: Breaking the Barrier to W1.58A4 PTQ for LLMs : PTQ 做到 1.58-bit 权重 + 4-bit 激活。

- NanoQuant: Efficient Sub-1-bit Quantization of LLMs: 低秩二值分解 + ADMM,把 PTQ 推到 sub-1-bit,刷新低显存前沿。

- LFQ: Logit-aware Final-block Quantization: 关注低比特量化后的生成质量,而不只是 PPL。

3) 量化被当成"可控压缩旋钮"来做理论

- Spotlight 论文 WaterSIC: 按信息论 waterfilling 给权重不同列分配不同量化率(1 – 4 bit),并用 rate – distortion / description-length 的框架去分析 GPTQ 这类算法。

- 这几乎就是把量化当率失真问题在做,和我想做的 KLT 旋转 + waterfilling 比特分配相似,说明这条路已被验证有效,我们需要加速出手。

4) FP4 格式研究爆发

- Block Rotation is All You Need for MXFP4 Quantization

- Unveiling the Potential of Quantization with MXFP4: Strategies for Quantization Error Reduction

- MXFP4 vs NVFP4(block size 32 vs 16、E8M0 vs E4M3 两级 scale)已经成了新的格式之争,这是 INT4/INT8 时代没有的战场,也最贴近真实部署。

5) KV Cache 压缩成为独立热点

- ManifoldKV: Training-Free KV Cache Compression via Euclidean Outlier Detection(淘汰派): 给每个历史 token 打重要性分,分低就丢。以前用 cosine 相似度打分,只看方向、丢掉了长度信息; ManifoldKV 改用欧氏距离(方向+幅度一起看),能抓住"幅度异常但方向普通"的重要 token。免训练、几行代码、换架构就能用。

- ParisKV: Fast and Drift-Robust KV-Cache Retrieval for Long-Context LLMs(检索派)——KV 全留着(可放 CPU 内存),但解码每步不做全注意力,只检索出最相关的 top-k 个 token 来算:先用哈希式碰撞粗筛候选,再用低精度量化内积精排,配合 CPU offload 撑到百万 token,而全注意力这时已经 OOM。

KV cache 压缩正在系统性地借用经典信息论 / 媒体压缩的工具: 变换编码(PCA 去相关 + 熵编码)、低秩投影、以及针对 RoPE 的比特分配。

VLA / Embodied:今年最热的应用赛道之一

现场 VLA 的密度明显高于去年:

- 动作生成向 diffusion / flow-matching + 更好的 action tokenizer 收敛;
- VLA 社区主要在做 Reasoning、RL、Diffusion、World Model。几乎没人真正研究 VLA 的低比特部署 (INT4/FP4/W4A4)、机器人端实时推理、VLA 的 PTQ/QAT 等问题。也就是说, "Efficient VLA" 还是一个比较空白的方向。如果能够结合 VLA 的特点设计量化方法 (例如 action token、视觉编码器、策略头等模块的差异化量化), 我认为这是未来一两年很有潜力的研究方向。

VLA 量化:未来可能做的方向

1. 把 MXFP4 / NVFP4 微缩格式引入 VLA 动作头

今年 ICML 的 FP4 研究爆发,但现有 VLA 量化几乎全是 INT(W4A4 / 1-bit),没人把 FP4 用到 flow-matching / diffusion 动作专家上,而 VLA 恰恰是边缘部署最典型的场景。研究动作专家在 FP4 下的格式误差与稳定性、MXFP4 vs NVFP4 的取舍是一个干净的空白点。

2. 面向连续/流式动作专家的 QAT 优化器稳定性研究

BitVLA 这类做了 QAT,但低比特训练的优化器振荡问题 (我之前 Adam 在 4-bit 权重上不收敛的问题,以及这次会议的 Scaling Law for QAT) 还没在 flow-matching 动作头上被研究过,而动作头对扰动比文本头敏感得多。可做一个 VLA 版的 QAT scaling / 优化器稳定性分析。

4. 闭环 / world-model 在环的量化标定

现在的 PTQ 标定本质是开环、逐层最小化重构误差;但 VLA 误差是闭环累积的。可以用闭环 rollout (或世界模型)产生的任务失败信号来驱动比特分配,而不是层级 MSE。

可跟进方向

1. rate-distortion / waterfilling 做量化已在 ICML 落地(WaterSIC), 那条线要尽快成文,否则窗口会关。
2. FP4 是新格式战场 具体角度: 格式误差建模 / 旋转变换 / 混合精度分配。
3. 低比特下的优化器稳定性+生成质量仍是缺口, 和我们 GRACE / QAT 的经验能直接接上,可作为下一篇的切口。