

VLA 方向的三个研究构想

方向一：让 token 预算跟着控制后果走

想法。现在的动作 tokenizer 都在做一件事：把动作序列压得又短又准，准指的是重建误差小。我想换一个失真的定义：不看动作本身重建得准不准，而看这个 token 错了之后，机器人 rollout 出去会差多少、安全裕度掉多少。一旦失真的定义换了，码率的分配方式也跟着变：自由空间里动作错几毫米无所谓，可以狠压；接触切换、抓取闭合、插孔对齐这些时刻错几毫米就全砸了，就该多花 token。也就是说，token 预算应该是可变的，跟着风险走，而不是全程一个固定码率。

现在很多人都已经意识到重建误差不是好目标，但每个人换的替代目标都不一样。OAT (2026.02) 明确说，低码率、低失真的编码还算不上一个好的策略接口，它补的第三个轴是 modelability，即自回归模型好不好预测。X-Tokenizer 和 Wall-OSS-0.5 补的是语义对齐，把动作 latent 拉向 VLM 的视觉特征。FASTer、NAC 则仍在优化重建保真度与码长的权衡。

大家换来换去，换的都还是代理指标，好不好建模、跟语义对不对齐，没有一个人把失真直接定义成**闭环控制后果**，而这恰恰是唯一可以真正测量的东西。而且上面所有 tokenizer 都是固定码率的，但控制后果在一个 chunk 内部差异极大，固定预算在信息论上是明显的浪费。

VLA 效率这一块（FlashVLA 之类的免训练加速，报出减少 55.7% FLOPs、36% 延迟、成功率只掉 0.7%）报的都是 FLOPs 和延迟，测的还都是准静态任务。压缩完到底有没有换来更高的闭环控制频率、在接触丰富的任务上到底有没有用，没人报。这正好可以作为我们评测部分的立场。

相关文献

- FAST: Efficient Action Tokenization for VLA Models — <https://arxiv.org/abs/2501.09747>
- OAT: Ordered Action Tokenization（明确提出低码率低失真 ≠ 好的策略接口） — <https://arxiv.org/abs/2602.04215>
- FASTer: Efficient Autoregressive VLA via Neural Action Tokenization — <https://arxiv.org/abs/2512.04952>
- X-Tokenizer: A Multimodal Action Tokenizer for VLA Pretraining（tokenizer 作为语义接口） — <https://arxiv.org/abs/2606.14752>
- ActionCodec: What Makes for Good Action Tokenizers — <https://arxiv.org/abs/2602.15397>
- SA-VLA: State-aware Tokenizer for VLA — <https://arxiv.org/abs/2606.30113>
- OmniSAT: Compact Action Token, Faster Auto Regression — <https://arxiv.org/abs/2510.09667>
- NAC: Neural Action Codec for VLA — <https://arxiv.org/abs/2606.21372>
- BEAST: Efficient Tokenization of B-Splines Encoded Actions — <https://openreview.net/forum?id=rQC11sf62w>
- VQ-VLA: Scaling Vector-Quantized Action Tokenizers (ICCV 2025) — <https://arxiv.org/abs/2507.01016>
- Wall-OSS-0.5 Technical Report（产品级模型用 Vision-Aligned RVQ 替换 FAST） — <https://arxiv.org/abs/2605.30877>

- FlashVLA / Think Twice, Act Once: Token-Aware Compression and Action Reuse — <https://arxiv.org/abs/2505.21200>
 - Bridging the Semantic-Action Gap in Visual Token Pruning for Efficient VLA Inference — <https://arxiv.org/abs/2511.16449>
-

方向二：让 VLA 学会「先试探，再动手」

想法。人拿瓶子前会先掂一下，开抽屉前会先轻拉一毫米试试卡不卡。现在的 VLA 完全不会。看一眼图片就直接工作，搞砸了才知道。我想让它学会花一两秒做试探动作，把关键的未知量测出来，再去做高风险的动作。

为什么这个问题绕不过去。现在所有世界模型 + VLA 的工作都在提高预测未来的能力。但有一类失败根本不是预测不准造成的，而是关键信息压根不在图像里：瓶里有没有水、摩擦系数多大、抽屉锁没锁、被遮挡的插孔偏了多少。这些量在静态观测下不可见，只有在特定的物-机交互中才显现。世界模型做得再逼真也没用，它也看不见。

ActiveVLA 加入主动视角选择和 3D 放大来应对遮挡，它解决的是看不见，而我们要解决看见了也测不出，它正好停在我们前面一步。第二，用交互估计物理参数这条经典路线很成熟（贝叶斯滤波估质量、质心、摩擦），但普遍依赖精确触觉传感和解析交互模型，从没进过 VLA，“估计”这个零件是现成的，缺的是试探行为自己从任务目标里长出来、并装进通用策略这一步。第三，VLA 这边所有跟不确定性有关的工作都是被动的：不确定就保守、就重规划，没有一篇是不确定就花个动作把它搞确定。这在控制论里叫 dual control，有几十年历史，但在 VLA 里是空白。

不做通用世界模型的不确定性（太难标定），只维护一个很小的、任务关键的未知量向量：瓶子重不重（三档）、抽屉卡不卡（是/否）、插孔偏多少。在规划器目标里加一项信息增益。当未知量会显著影响成败时，最优解自然就包含试探动作，不用人写规则。训练分两步：先在仿真里用上帝视角真值训练估计器和试探规划器，再把试探行为蒸馏进 VLA。

相关文章

- ActiveVLA: Injecting Active Perception into VLA Models — <https://arxiv.org/abs/2601.08325>
 - Predictive Visuo-Tactile Interactive Perception Framework for Object Properties Inference — <https://arxiv.org/abs/2411.09020>
 - Push to know! Visuo-Tactile Active Object Parameter Inference with Dual Differentiable Filtering — <https://arxiv.org/abs/2308.01001>
 - PI-VLA: Adaptive Symmetry-Aware Decision-Making (含 Active Uncertainty-Resolving Decider) — <https://www.mdpi.com/2073-8994/18/3/394>
 - Perturbation-Based Uncertainty for Failure Detection in VLA — <https://arxiv.org/abs/2606.20754>
 - PhysReflect-VLA: Physical Feasibility and Self-Reflective Regulation — <https://arxiv.org/abs/2606.27146>
 - LaWAM: Latent World Action Models for Efficient Dynamics-Aware Robot Policies — <https://arxiv.org/abs/2606.15768>
-

方向三：把控制知识装进 VLA 脑子里，而不是外面挂个优化器

想法。现在让 VLA 变安全、变平滑的做法，都是在它后面接一个优化器或安全层：VLA 出个动作，优化器改一改再执行。问题是优化器得一直开着，一关就打回原形。我想做的是：训练时用优化器教，推理时把优化器关掉，VLA 自己就能给出又安全又平滑的动作。另一半是：世界模型不要再预测未来图像，只预测控制器真正用得着的量：物体在哪、接触上没有、末端位姿、关节状态，以及这些预测有多不确定。图像里绝大部分像素跟控制无关。我初步的想法是训练时用世界模型 + 可微 MPC 教 VLA，然后推理时把 MPC 整个关掉，看性能还剩多少。

相关文献

- WorldVLA: Towards Autoregressive Action World Model — <https://arxiv.org/abs/2506.21539>
- RynnVLA-002: A Unified Vision-Language-Action and World Model — <https://arxiv.org/abs/2511.17502>
- GPC: Inference-Time Enhancement of Generative Robot Policies via Predictive World Modeling (RA-L 2026) — <https://arxiv.org/abs/2502.00622>
- World Model for Robot Learning: A Comprehensive Survey — <https://arxiv.org/abs/2605.00080>
- DiffOG: Differentiable Policy Trajectory Optimization with Generalizability (T-RO 2025) — <https://arxiv.org/abs/2504.13807>
- Differentiable Predictive Control with Safety Guarantees: A Control Barrier Function Approach (最重要的一篇：证明 MPC 可蒸馏进神经网络策略，但只在经典控制上做过) — <https://arxiv.org/abs/2208.02319>
- Differentiable MPC for End-to-end Planning and Control (NeurIPS 2018) — <https://arxiv.org/abs/1810.13400>
- BarrierNet: Differentiable Control Barrier Functions for Learning of Safe Robot Control (T-RO 2023) — <https://arxiv.org/abs/2003.09140>
- SafeFlow: Safe Robot Motion Planning with Flow Matching via Control Barrier Functions — <https://arxiv.org/abs/2504.08661>
- VLSA: Vision-Language-Action Models with Plug-and-Play Safety — <https://arxiv.org/abs/2512.11891>
- Diffusion Policy: Visuomotor Policy Learning via Action Diffusion — <https://arxiv.org/abs/2303.04137>

小结

方向一说的是这串动作里，哪几个 bit 真正关乎成败，就该把预算花在哪；方向二说的是不确定的时候，应该花动作去把它搞确定，而不是硬着头皮上；方向三说的是安全和平滑应该是 VLA 自己就懂的事，而不是靠外面挂个优化器兜底。